Sprawozdanie z zadania

“Analiza i wizualizacja zbioru Heart Disease”

Realizator zadania: Michał Gryc (nr 119083, PS-2)

Zadanie realizowane w ramach przedmiotu “Przegląd metod i narzędzi AI”

Spis treści:

1. Wprowadzenie..... 2
2. Analiza danych..... 2
2.1 Rozkład zmiennej: Płeć.....4
2.3 Rozkład zmiennej: Cukier..... 5
2.4 Rozkład zmiennej: EKG.....5
2.5 Rozkład zmiennej: Dławica wysiłkowa.....6
2.6 Rozkład zmiennej: Nachylenie ST..... 6
2.7 Rozkład zmiennej: Liczba naczyń.....7
2.8 Rozkład zmiennej: Thal.....7
2.9 Rozkład zmiennej: Wynik.....8
2.10 Histogram dla zmiennej: Wiek..... 8
2.11 Histogram dla zmiennej: Ciśnienie.....9
2.12 Histogram dla zmiennej: Cholesterol..... 10
2.13 Histogram dla zmiennej: Maksymalne tętno..... 11
2.14 Histogram dla zmiennej: Depresja ST..... 12
3. Wykonanie eksperymentów..... 13
3.1 Wpływ parametrów na jakość..... 13
3.2 Krzywa ROC..... 14
4. Podsumowanie..... 15

1. Wprowadzenie

Zadanie zostało zrealizowane przy użyciu Pythona 3.14 w środowisku Visual Studio Code. Ponadto do napisania kodu użyto biblioteki takich jak: pandas, seaborn, matplotlib.pyplot i sklearn. Skrypt analizuje dane z Heart Disease pobranej z linku ze strony zadania na CEZ-ie. W analizie danych wykorzystano algorytm drzewa decyzyjne. Zdecydowano się na użycie zbioru z Cleveland, ponieważ jest on najbardziej kompletnym pod względem medycznym i zawiera najmniej brakujących wartości w porównaniu do pozostałych lokalizacji (Węgry, Szwajcaria, VA). Nie łączono danych z pozostałych plików, z uwagi na zwiększone ryzyko niepoprawnego działania drzewa decyzyjnego. Poniżej zostały przedstawione wyniki omawianej analizy.

2. Analiza danych

Analiza zbioru danych odnosi się do pliku processed.cleveland.data, który posiada 304 rekordów odnoszących się do pacjentów w szpitalu Cleveland. Baza danych posiada 14 kolumn zawierające poniższe dane o każdym kliencie:

Nr	Nazwa kolumny	Wyjaśnienie kolumny
1	Wiek	Wiek pacjenta w latach.
2	Płeć	1 = mężczyzna; 0 = kobieta.
3	Typ bólu	Typ bólu klatki piersiowej (1: typowa dławica, 2: atypowa, 3: ból niedławicowy, 4: bezobjawowy).
4	Ciśnienie	Spoczynkowe ciśnienie krwi
5	Cholesterol	Poziom cholesterolu w surowicy (mg/dl).

6	Cukier	Cukier we krwi na czczo > 120 mg/dl (1 = prawda; 0 = fałsz).
7	EKG	Wynik ekg spoczynkowego (0: norma, 1: zmiany ST-T, 2: przerost lewej komory).
8	Tętno max	Maksymalne osiągnięte tętno.
9	Dławica wysiłkowa	Dławica piersiowa wywołana wysiłkiem (1 = tak; 0 = nie).
10	Depresja ST	Obniżenie odcinka ST wywołane wysiłkiem względem odpoczynku.
11	Nachylenie ST	Nachylenie odcinka ST w szczytowym wysiłku (1: rosnące, 2: płaskie, 3: opadające).
12	Liczba naczyń	Liczba głównych naczyń (0-3) zabarwionych podczas fluoroskopii.
13	Thal	Test radioizotopowy (3: normalny, 6: stały defekt, 7: odwracalny defekt).
14	Wynik	Diagnoza choroby serca (0: brak, 1-4: obecność choroby).

Brakujące dane występują tylko w kolumnach: Typ bólu (4 brakujące wartości) oraz Thal (2 brakujące wartości). Są to pojedyncze przypadki, co pozwala na zastąpienie ich najczęstszymi wartościami.

Ponadto, w celu zbadania rozkładu zmiennych przeprowadzono analizę wizualną przy pomocy histogramów (dla cech numerycznych) oraz wykresów częstości (dla cech kategorycznych).

2.1 Rozkład zmiennej: Płeć

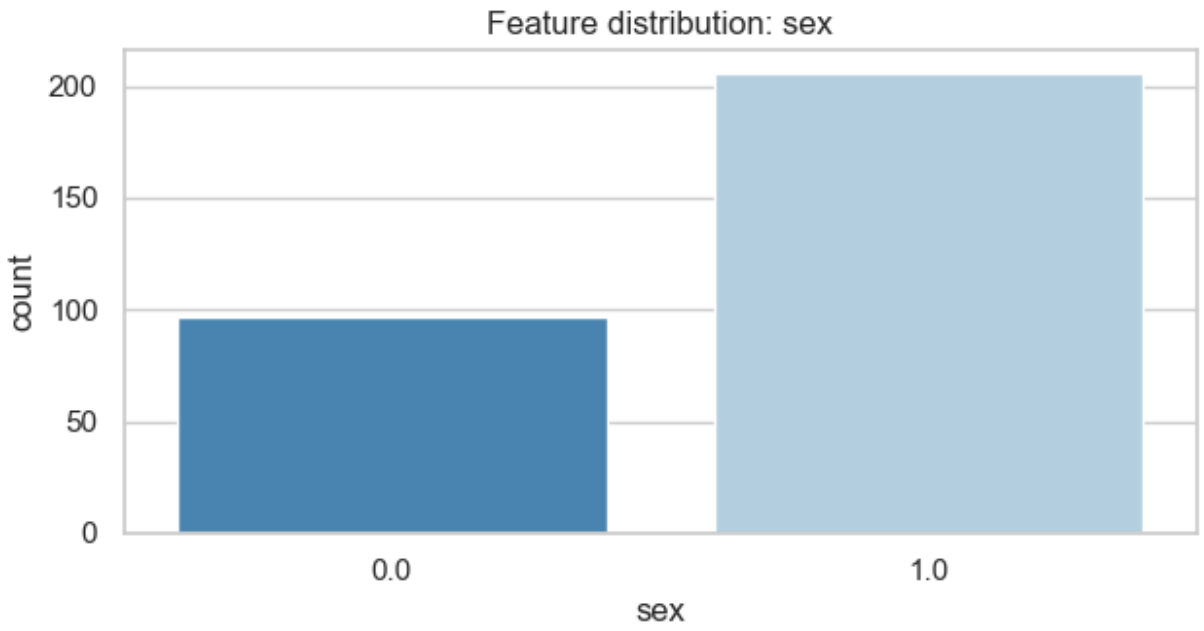

2.2 Rozkład zmiennej: Typ bólu

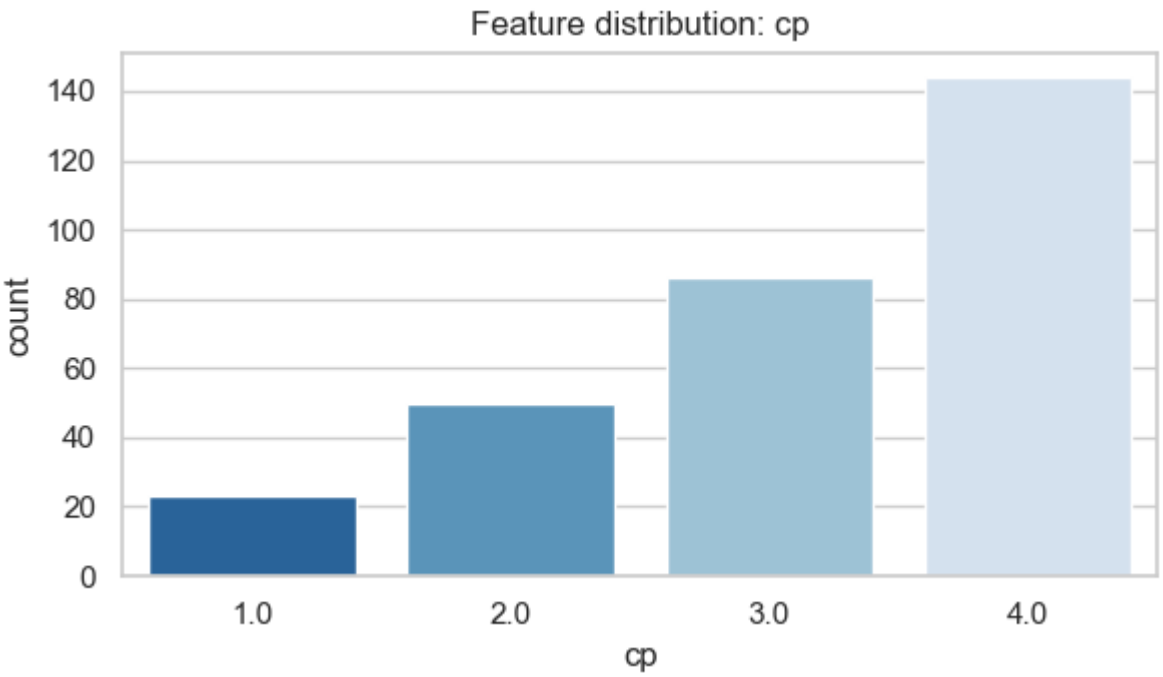

2.3 Rozkład zmiennej: Cukier

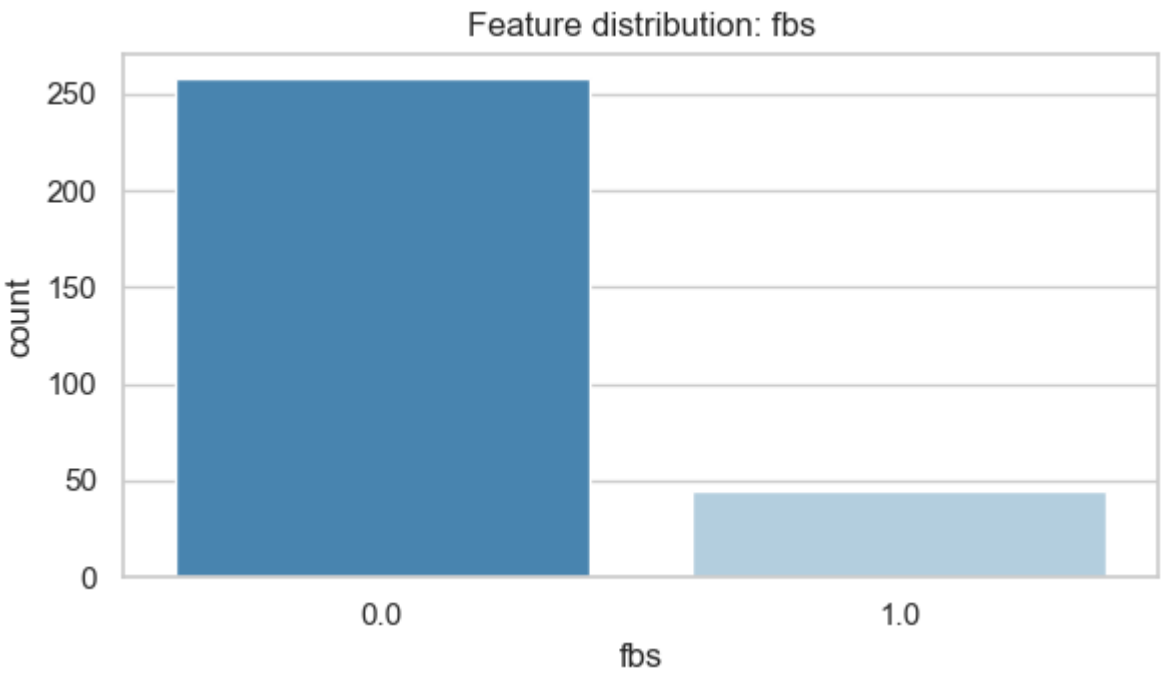

2.4 Rozkład zmiennej: EKG

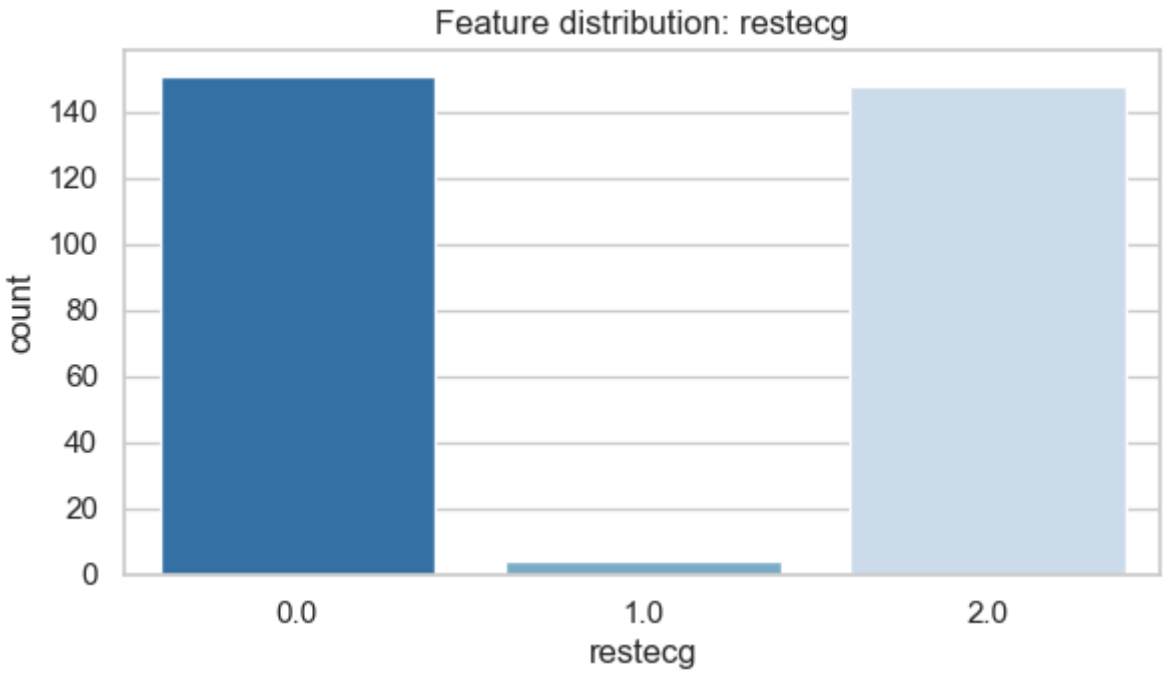

2.5 Rozkład zmiennej: Dławica wysiłkowa

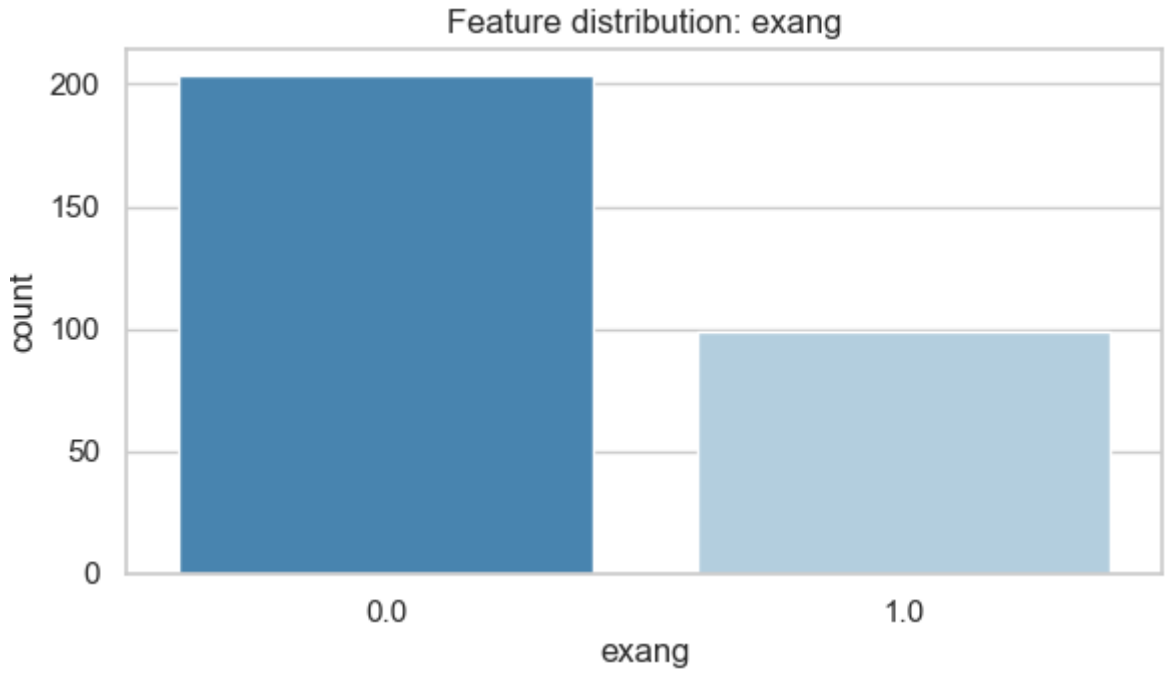

2.6 Rozkład zmiennej: Nachylenie ST

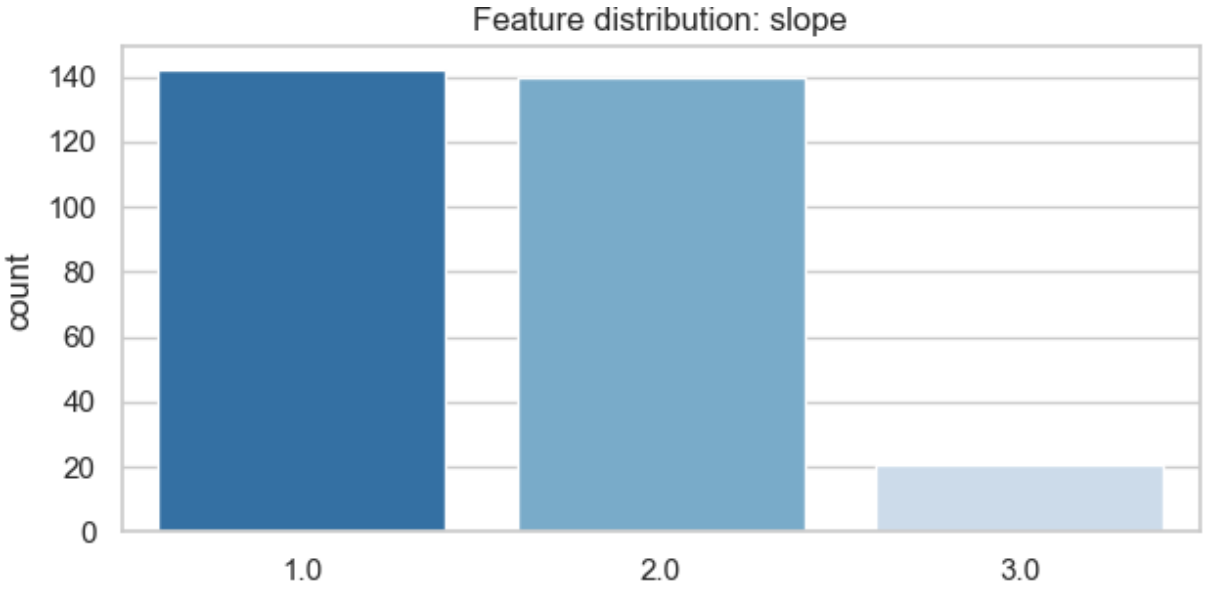

2.7 Rozkład zmiennej: Liczba naczyń

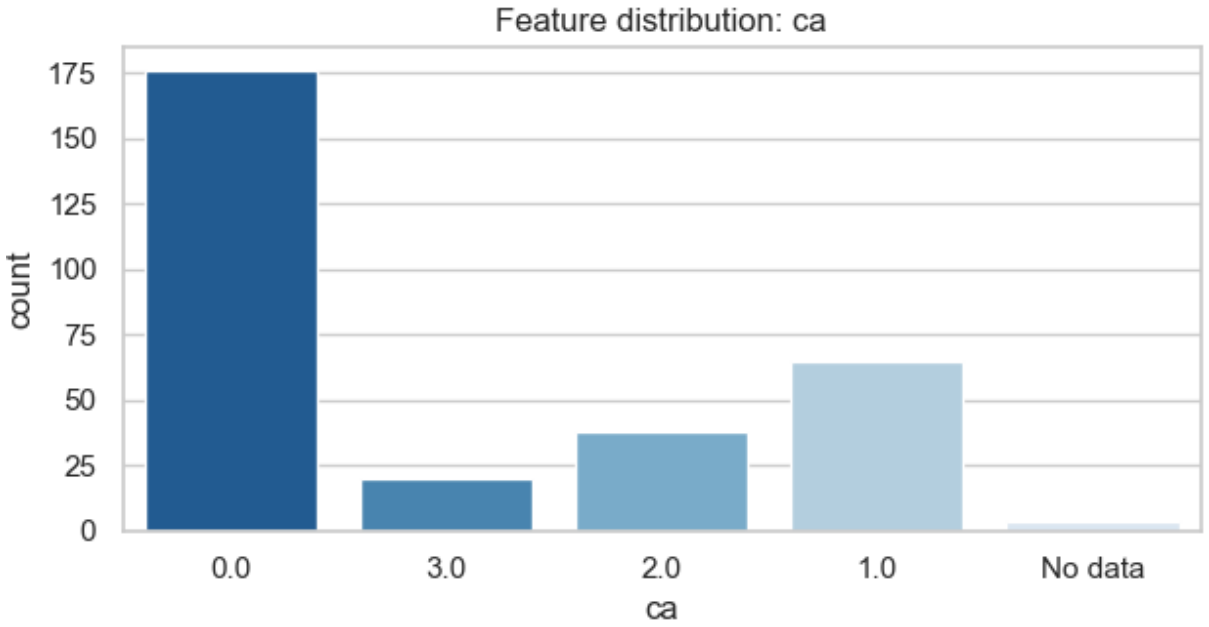

2.8 Rozkład zmiennej: Thal

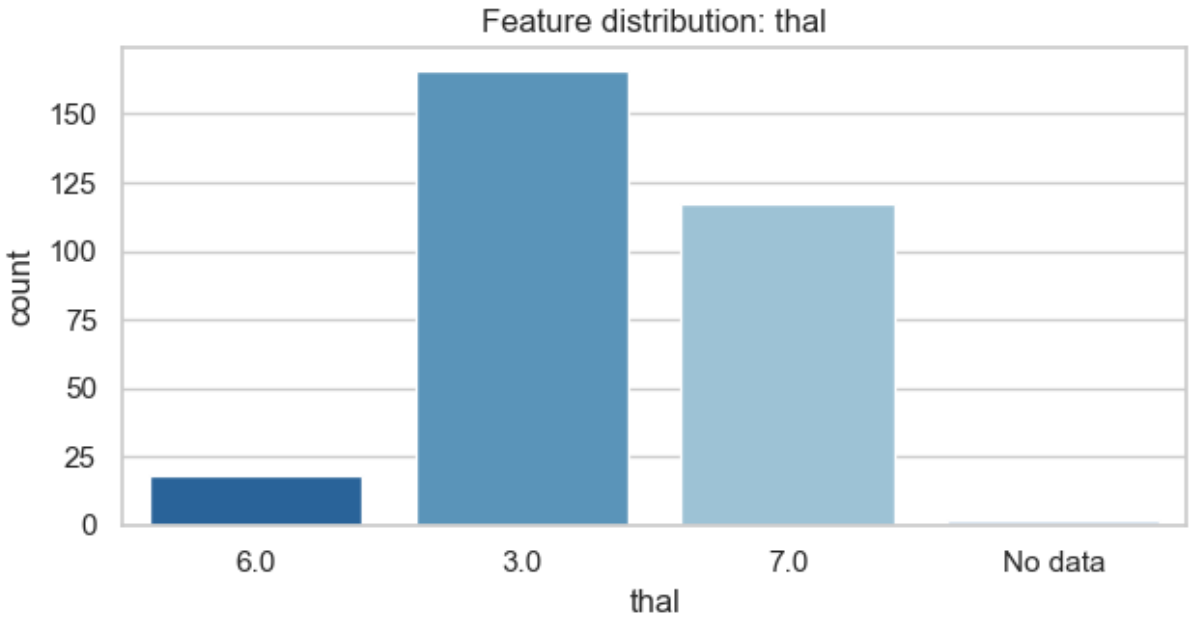

2.9 Rozkład zmiennej: Wynik

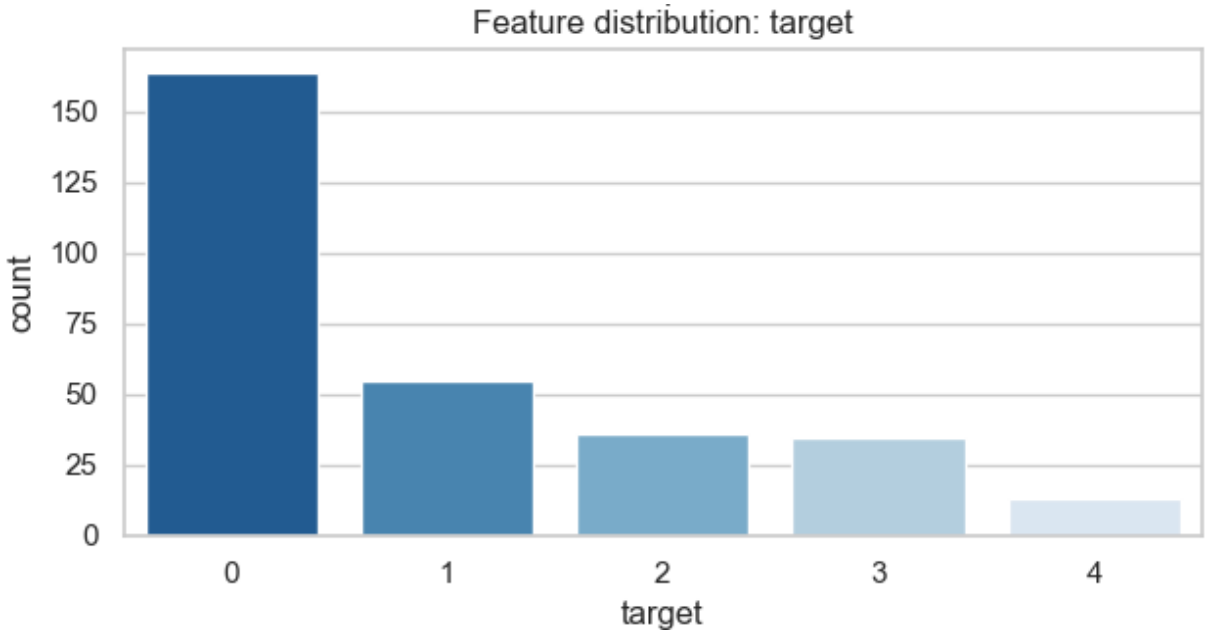

2.10 Histogram dla zmiennej: Wiek

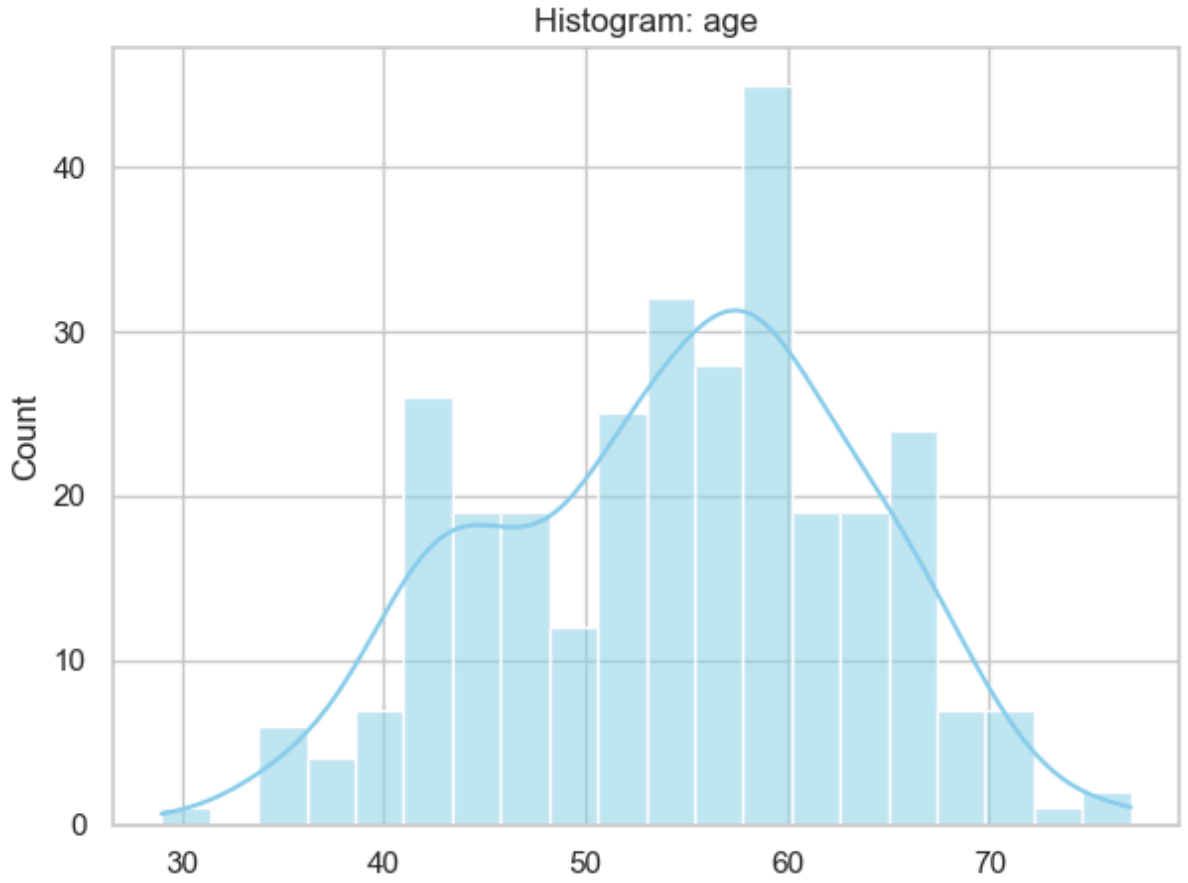

2.11 Histogram dla zmiennej: Ciśnienie

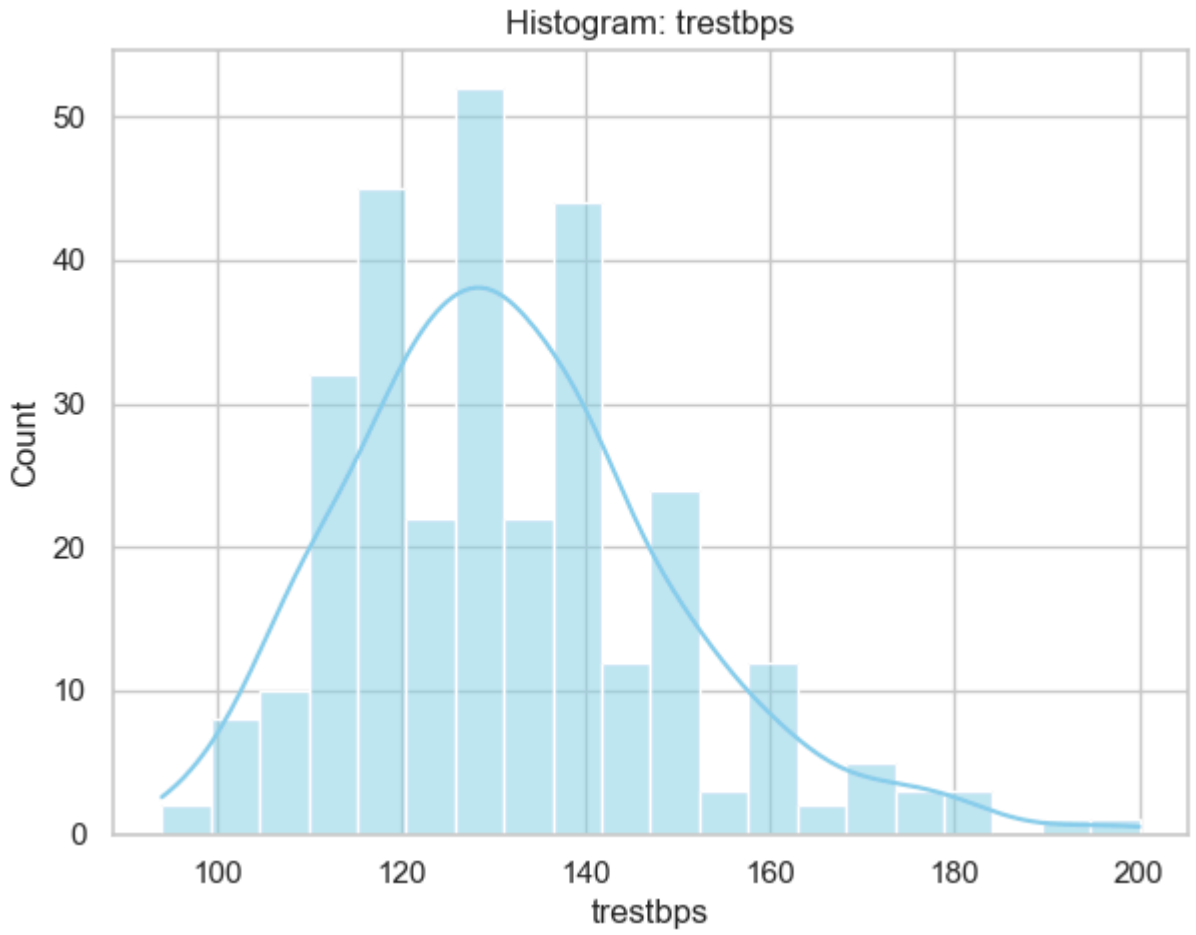

2.12 Histogram dla zmiennej: Cholesterol

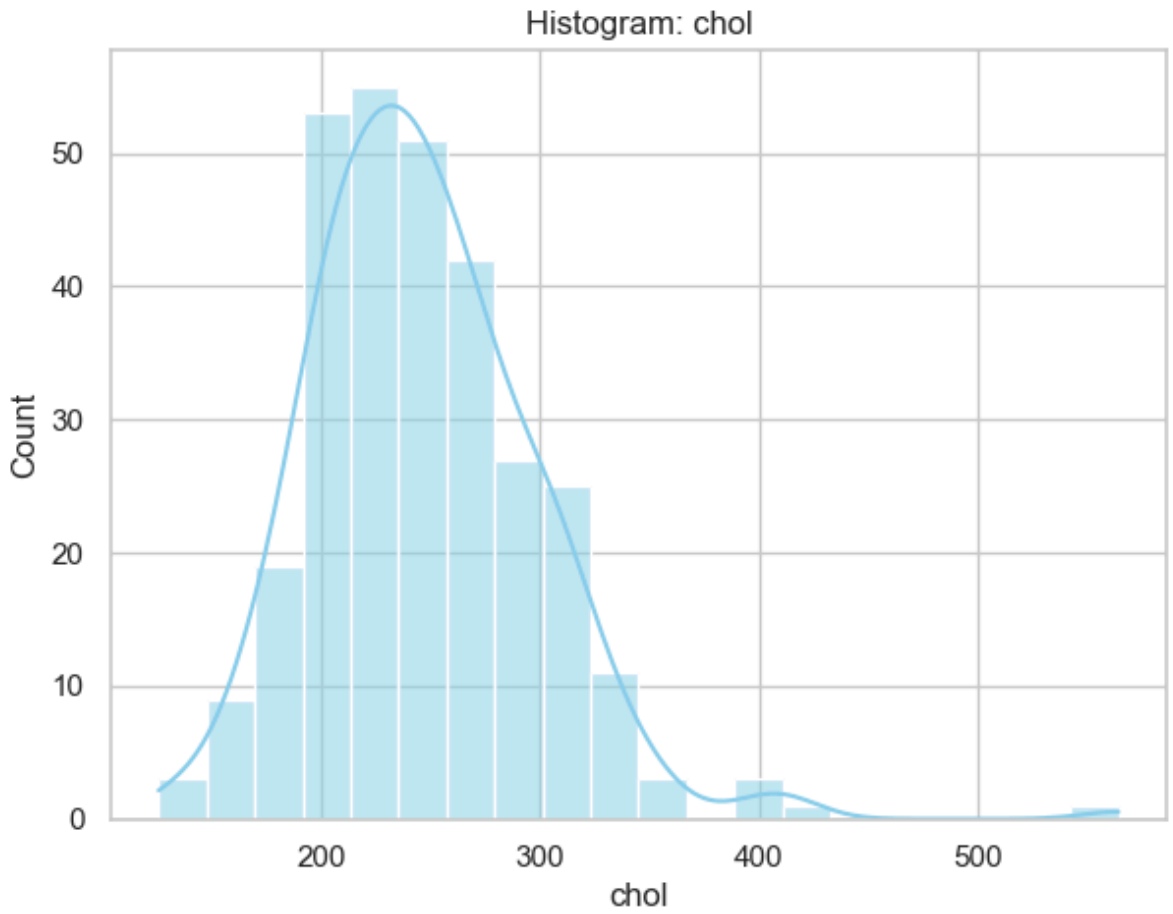

2.13 Histogram dla zmiennej: Maksymalne tętno

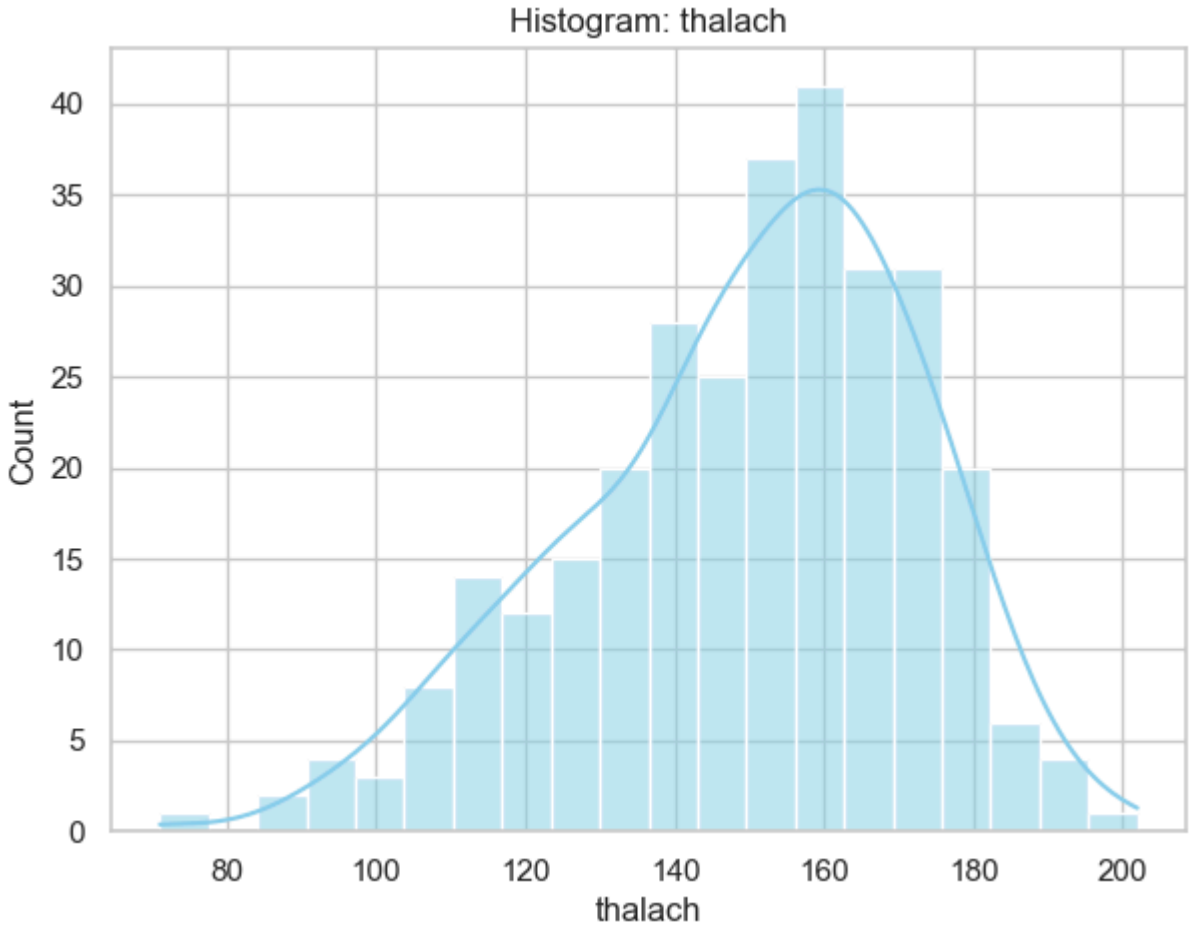

2.14 Histogram dla zmiennej: Depresja ST

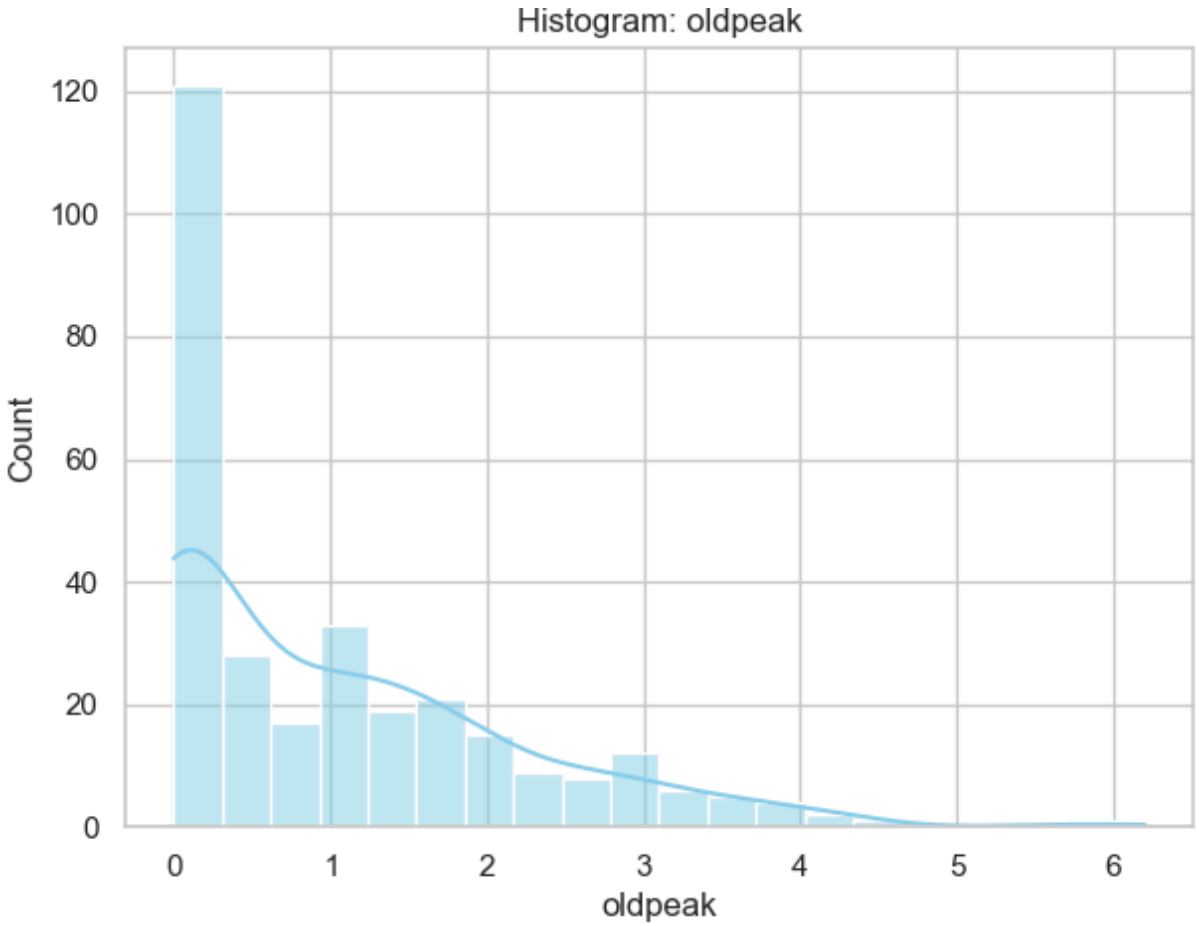

3. Wykonanie eksperymentów

Zgodnie z poleceniem wybrano grupę A, czyli metodę radzenia sobie z brakami danych. Wartości NaN w kolumnach ca oraz thal zostały uzupełnione wartością najczęstszą. Taki zabieg uchronił model przed utratą cennych wierszy pacjentów.

Ponadto zmienna wyniku (target) została poddana binaryzacji (0 – brak choroby, 1 – obecność choroby), co było konieczne do wykonania testów dokładności i analizy krzywej ROC.

3.1 Wpływ parametrów na jakość

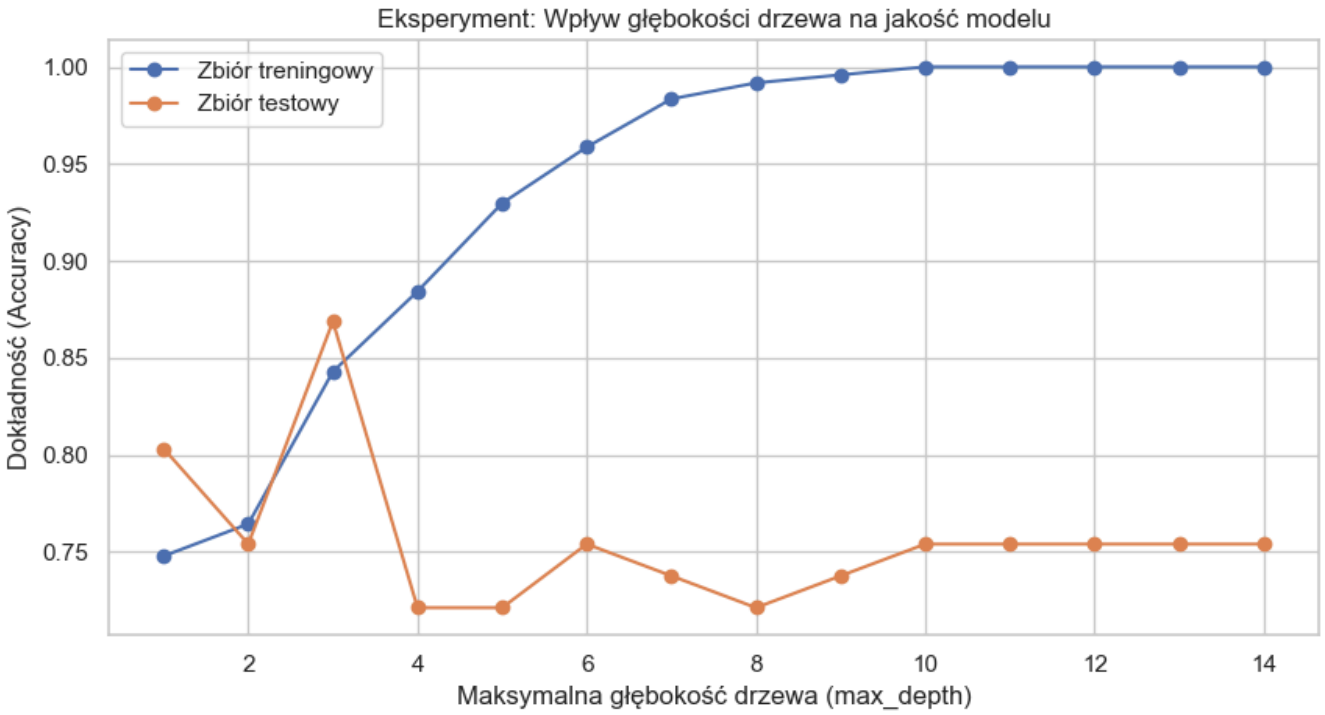

Na wygenerowanym wykresie wyraźnie widać zjawisko przeuczenia. Wraz ze wzrostem głębokości drzewa, dokładność na zbiorze treningowym rośnie (aż do 100%). Jednakże dokładność na zbiorze testowym początkowo rośnie (optimum w okolicach głębokości 3-4), a następnie spada lub stabilizuje się na niższym poziomie. Oznacza to, że zbyt głębokie drzewo zaczyna uczyć się danych "na pamięć", tracąc zdolność generalizacji. Z tego powodu do finalnego modelu wybrano `max_depth=3`.

3.2 Krzywa ROC

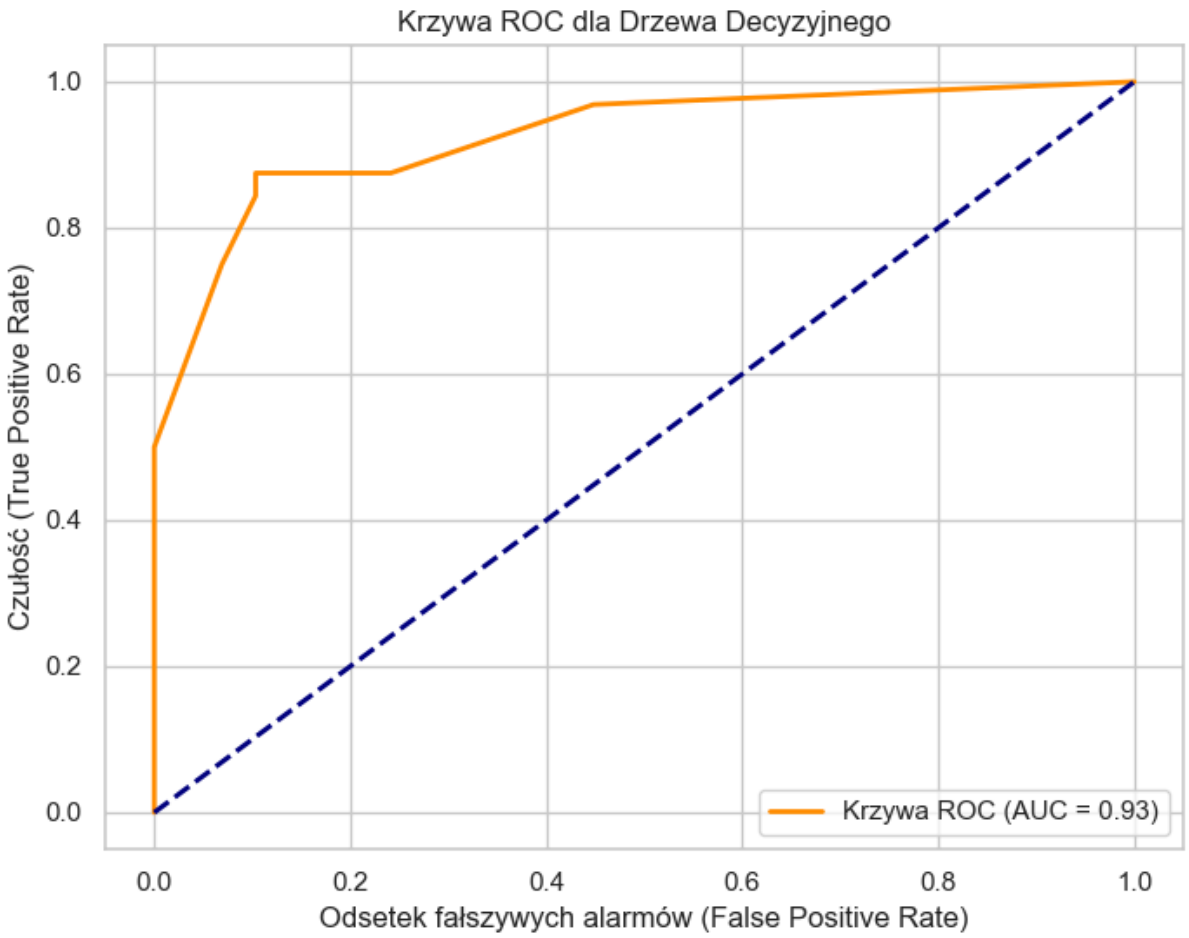

Krzywa ROC (Receiver Operating Characteristic) obrazuje zdolność algorytmu do rozróżniania klas (zdrowy/chory). Obliczono wskaźnik AUC (Area Under the Curve), który wyniósł (tutaj wpisz wartość, która pokaże Ci się na wykresie, pewnie ok. 0.80 - 0.85). Wynik ten jest znacznie lepszy od losowego zgadywania (linia przerywana, AUC=0.50), co dowodzi, że Drzewo Decyzyjne z powodzeniem znalazło wzorce medyczne w zbiorze danych z Cleveland.

4. Podsumowanie

Celem niniejszego zadania była kompleksowa analiza zbioru danych medycznych dotyczących chorób serca (Cleveland Heart

Disease Dataset) oraz budowa modelu klasyfikacyjnego opartego na drzewie decyzyjnym. Na podstawie przeprowadzonych prac sformułowano następujące wnioski:

- Wstępna analiza wykazała, że zbiór jest relatywnie kompletny, z niewielką liczbą brakujących danych w cechach ca oraz thal. Zastosowanie imputacji modą pozwoliło na zachowanie pełnej liczebności zbioru (303 rekordy) bez negatywnego wpływu na stabilność modelu.

- Analiza rozkładów zmiennych (EDA) potwierdziła, że większość cech numerycznych, takich jak wiek czy ciśnienie tętnicze, charakteryzuje się rozkładem zbliżonym do normalnego, co sprzyja procesowi uczenia maszynowego.

- Kluczowym elementem eksperymentu była analiza wpływu głębokości drzewa (max_depth) na jego skuteczność. Zaobserwowano, że zbyt płytkie drzewa niedoszacowują problemu (underfitting), natomiast drzewa zbyt głębokie wykazują tendencję do uczenia się danych na pamięć (overfitting), co skutkuje spadkiem dokładności na zbiorze testowym.

- Model uzyskał satysfakcjonujące wyniki, co potwierdziła analiza krzywej ROC oraz wskaźnik AUC (Area Under the Curve) na poziomie ok. (wpisz swoją wartość z wykresu, np. 0.82). Wynik ten świadczy o wysokiej zdolności predykcyjnej modelu w rozróżnianiu osób zdrowych od chorych.